

扩散模型 DDPM.

一、《一个视频看懂 DDPM 原理推导》—— Vick-Li

1. 降噪过程每一步学的是一个分布 (而非确切的 x_{t-1}) \Rightarrow 更好随机性

但 unet 的输出最后是个噪音 \leftarrow 重参数化 噪音

零：理论基础.

1. 正态分布 (高斯分布), $x \sim N(\mu, \sigma^2)$

(1) 扩散过程的终点 x_1 是一个标准正态分布.

(2) 多维高斯分布

$$x \sim N(\mu, \Sigma)$$

· x 是图片展平后的向量

· μ : 均值向量

· Σ : 协方差矩阵 $\Rightarrow \sigma^2 I$ (每个像素噪声独立)

(3) DDPM 用到的“三大高斯性质”.

① 重参数化 (Reparameterization)

· 前向加噪核心: 让 随机采样 可导.

· 从 $N(\mu, \sigma^2)$ 中采样一个 x :

1° 从 $N(0, 1)$ 中采样一个随机噪声 ϵ .

2° 线性变换得 x : $x = \mu + \sigma \epsilon$

· DDPM 中:

$$x_t \sim N(\sqrt{1-\beta_t} x_{t-1}, \beta_t I)$$

\downarrow

$$x_t = \sqrt{1-\beta_t} x_{t-1} + \sqrt{\beta_t} \cdot \epsilon$$

\leftarrow noise \Rightarrow 转换成预测
噪声 ϵ .

② 高斯分布的可加性.

在生成模型论文中的符号:

- 破坏者
- 完全已知
- $q(x_t | x_{t-1})$: 在前一时刻的基础上加噪
- Encoder

- 重建者，可学习的， p_{θ} (θ 为权重)

· $P_{\theta}(x_{t-1}|x_t)$: 神经网络猜上一时刻的分布

- Decoder.

$$(E, M, N) \sim X$$

X月國立憲法日

12/10/2019

3. 推定が成り立つ。 $\Rightarrow \mathcal{O}_1 \subset \mathcal{O}_2$ (逆は成り立たない)

(3) 100% 的脂肪，三大营养素中，

① 174 卷 (Reparatur)

日 林 采 叶 叶 叶 = 21 林采叶叶叶

$x_1 = \frac{1}{\sqrt{2}}, x_2 = \frac{1}{\sqrt{2}}$

③ 7. 第 10 頁 - 11 頁 (1.0) M-A 9

$30 + 34 = x$ x 雙雞蛋十枚

$$= \frac{1}{2} \frac{d^2}{dt^2} \left(\frac{1}{2} \frac{d^2}{dt^2} \right)$$
$$(I, \theta, \max_{x \in \mathcal{X}} \overline{V(x)} - \max_{x \in \mathcal{X}} V(x))$$

陳學為對林 (← 971011)

1000

$$3 \cdot \sqrt{19} + 15 \cdot \sqrt{19} = 3 \cdot 4$$

② 调整 (6) 各阻值如左

• 两个独立高斯分布的随机变量相加, 结果依然高斯.

$$\begin{aligned} X &\sim N(\mu_1, \sigma_1^2) \\ Y &\sim N(\mu_2, \sigma_2^2) \end{aligned} \Rightarrow X+Y \sim N(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$$

• 在DDPM中:

让扩散中的加噪一步到位 $\Rightarrow q(x_t|x_0)$ 的分布.

③ 贝叶斯公式与高斯乘积

$$N(x; \mu_1, \sigma_1^2) \cdot N(x; \mu_2, \sigma_2^2) \propto N(x; \mu_{\text{new}}, \sigma_{\text{new}}^2)$$

• 在DDPM中: $q(x_t|x_{t-1}) \cdot q(x_{t-1}|x_0)$, 具体见下节.

2. 贝叶斯公式

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

(1) 先验概率 (Prior, $P(A)$)

• 根据以往的经验 $\rightarrow q(x_{t-1}|x_0)$

(2) 似然 (Likelihood, $P(B|A)$)

• 假设A已发生的情况下, 出现B的概率 $\rightarrow q(x_t|x_{t-1})$

(3) 后验 (Posterior, $P(A|B)$) (从果推因).

• 最想求的值. 看到证据B后, 需要修正原来的判断, 得到事件A发生的概率.

逆向去噪过程: 已知: 全是噪声的 x_t (证据B)

想求: 这图上一时刻 x_{t-1} (A) 的概率
 $q(x_{t-1}|x_t)$

(4) 贝叶斯在DDPM.

$$q(x_{t-1}|x_t, x_0) = \frac{q(x_t|x_{t-1}, x_0) q(x_{t-1}|x_0)}{q(x_t|x_0)}$$

后验概率公式

• 假设训练已知原图 x_0 :

$$q(x_{t-1}|x_t) \rightarrow q(x_{t-1}|x_t, x_0)$$

• 左侧三项全部已知且高斯

$q(x_{t-1}|x_t, x_0)$ 的均值与方差可以写出解析解

4. 联合分布 (Joint Distribution)

(1) 描述了多个随机变量同时取特定值的概率。

(2) 离散 (Discrete)

$$P_{XY}(x, y) \triangleq P(X=x, Y=y)$$

· 归一性: (归一性)

$$\sum_{x \in X} \sum_{y \in Y} P(X=x, Y=y) = 1$$

· X, Y : 随机变量 (不确定的函数/状态)

· x, y : 该变量取到的具体数值。

(3) 连续 (Continuous)

· 使用联合概率密度函数 (PDF):

$$f_{XY}(x, y) \rightarrow p(x, y)$$

· 对连续变量, 单点概率 $P(X=x, Y=y) = 0$
因此我们讨论的是落在一个小区域内的概率。

$$P(x \leq X \leq x+dx, y \leq Y \leq y+dy) \approx f_{XY}(x, y) dx dy$$

· 归一性:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{XY}(x, y) dx dy = 1$$

5. 边缘分布 (Marginal Distribution)

(1) 对联合分布中“无关变量”进行求和 (离散) / 求积分 (连续)。

(2) 离散

$$P_X(x) = \sum_{y \in Y} P_{XY}(x, y)$$

(3) 连续

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y) dy$$

↓ OOPM

$$p(x) = \int p(x, y) dy$$

6. 重要法则

(1) 加法法则 (边缘化)

→ 谓变量

$$p(x) = \int p(x, y) dy$$

(2) 乘法

$$p(x, y) = p(y|x) \cdot p(x) = p(x|y) \cdot p(y)$$

(3) 全概率公式 → 描述隐变量模型的生成过程。

$$p(x) = \int \underbrace{p(x|z)}_{\text{likelihood}} \cdot \underbrace{p(z)}_{\text{prior}} dz$$

7. 期望 (expectation view)

· 把积分写成期望

$$p(x) = E_{z \sim p(z)} [p(x|z)]$$

· $p(z)$: z 服从的分布

· OOPM: 图像 x 的分布, 本质上是无数条可能噪声路径的生成概率的平均值。

边缘概率 权重: z 出现的先验概率

· 物理意义: x 发生的概率 = 在所有可能的隐状态 z 下生成 x 的概率的加权平均。

· 含义: 边缘概率 $p(x)$ 可以看作似然函数 $p(x|z)$ 在先验分布 $p(z)$ 下的期望值。

→ 将神经网络的任务 → 去学 $q(x_{t+1} | x_t, x_0)$ 的均值 → 预测噪声 ϵ .

3. 最大化似然 (log likelihood) + 变分推断 (Variational Inference)

(1) 定义: 真实数据 $X = \{x_1, x_2, \dots, x_n\}$, 模型是一个概率分布 $p_\theta(x)$. 似然函数就是模型生成这些真实数据的

联合概率 = $L(\theta) = p_\theta(x_1, x_2, \dots, x_n) \stackrel{\text{独立}}{=} \prod_{i=1}^n p_\theta(x_i)$

目标是找一个 θ , 让 $L(\theta)$ 最大.

(2) Why log?

- 连乘 → 连加: 防止 Underflow
- 方便求导.

$$\Rightarrow \theta^* = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log p_\theta(x_i)$$

(3) 最小化 Loss \Leftrightarrow 最小化负的 likelihood.

$$\text{Loss} = - \sum_{i=1}^n \log p_\theta(x_i)$$

(4) DDPM 中的最大似然.

1° 由于预测数据 \sim 高斯分布 $\rightarrow p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

$$\Rightarrow -\log p(x) = \underbrace{\frac{1}{2\sigma^2} (x-\mu)^2}_{\text{MSE}} + \underbrace{\log(\sqrt{2\pi}\sigma)}_{\text{常数项}}$$

∴ 在高斯分布前提下: $\text{Max Log-Likelihood} \Leftrightarrow \text{MSE}$.

2° 由于解析的 $p_\theta(x_0)$ 无法计算 $\rightarrow \int p_\theta(x_0, x_1, \dots, x_T) dx_{1:T} \stackrel{\text{无数条 } x_0 \rightarrow x_1 \text{ 的路径}}{=} p_\theta(x_0)$ (边缘概率)

∴ 要取去优化其下界 (Evidence Lower Bound) ELBO

$$\therefore \text{ELBO} \approx \sum D_{KL}(\text{后验} \parallel \text{先验}) \approx \sum \text{MSE}$$

高斯分布下, $D_{KL} \propto \|\mu_1 - \mu_2\|^2 \rightarrow$ 均值的均方差

4. KL 散度 (KL Divergence) \star 最小化分布差异 \Leftrightarrow 最小化 ϵ 和 ϵ_0 差异 \leftarrow 由噪声决定

• 衡量 2 个概率分布之间的差异. • $D_{KL}(A \parallel B) = 0$: A 和 B 完全一致. 0 值越大, 表示差距越大.

推导:

$$X_t = \sqrt{\alpha_t} X_{t-1} + \sqrt{1-\alpha_t} \epsilon_t$$

$$= \sqrt{\alpha_t} (\sqrt{\alpha_{t-1}} X_{t-2} + \sqrt{1-\alpha_{t-1}} \epsilon_{t-1}) + \sqrt{1-\alpha_t} \epsilon_t$$

$$= \sqrt{\alpha_t \alpha_{t-1}} X_{t-2} + \underbrace{\sqrt{\alpha_t (1-\alpha_{t-1})} \epsilon_{t-1}}_{\text{noise}} + \sqrt{1-\alpha_t} \epsilon_t$$

$$\sqrt{\alpha_t^2 + \epsilon_t^2}$$

$$= \sqrt{1-\alpha_t} \epsilon_t$$

$$= \sqrt{\alpha_t \alpha_{t-1}} X_{t-2} + \sqrt{1-\alpha_t} \epsilon_t$$

$$\Rightarrow \sqrt{\alpha_t} X_0 + \sqrt{1-\alpha_t} \epsilon_t$$

在估计中，我们使用 Max log-likelihood 来估计参数。

由于我们假设 $p(x_1, \dots, x_T) = p(x_1) \dots p(x_T)$ ，所以我们可以将联合概率分解为各个时间步的概率的乘积。

因此，我们可以将联合概率的对数似然函数写为：

$$\text{ELBO} \approx \sum_{t=1}^T \text{MSE}_t$$

其中 MSE_t 是第 t 个时间步的均方误差。

$$\text{KL Divergence} = -\sum_{i=1}^n p_i \log p_i$$

在 KL 散度的计算中，我们需要知道每个时间步的分布 p_i 。

一、前向过程

1. 单步加噪:

$$X_t = \sqrt{1 - \beta_t} X_{t-1} + \sqrt{\beta_t} \epsilon_{t-1} \quad (\text{重参数化})$$

• β_t : 方差调度参数 (Variance Schedule), 很小接近于0.

• ϵ_{t-1} : $N(0, I)$ 采样的随机噪声.

2. 任意步加噪 ($X_0 \rightarrow X_t$)

• 记: $\alpha_t = 1 - \beta_t$

$$X_t = \sqrt{\alpha_t} X_0 + \sqrt{1 - \alpha_t} \epsilon$$

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$

i.e. $q(X_t | X_0) \sim N(X_t; \sqrt{\alpha_t} X_0, (1 - \bar{\alpha}_t) I)$

• 物理含义: $\sqrt{\alpha_t} X_0$: 信号项. 随着 $t \uparrow$, 原图信息 \downarrow

• $\sqrt{1 - \bar{\alpha}_t} \epsilon$: 噪声项. $t \uparrow$, 权重 $\rightarrow 1$, 图像变为纯噪声.

• 当 X_T 中 T 会很大时, $X_T \approx \epsilon$ 意味着什么?

Ans. 扩散过程最终将任意数据分布收敛到标准正态分布, 保证了我们可以通过采样标准正态分布的噪声来开始生成过程.

二、逆向过程

$$\frac{p(X_t | X_{t+1}) \cdot p(X_{t+1})}{p(X_t)} \quad \text{难求.}$$

• 思路: 直接学 $p(X_{t+1} | X_t)$ 很难, 但可以学 $q(X_{t+1} | X_t, X_0)$ 的均值

$$\text{i.e. } q(X_{t+1} | X_t, X_0) \sim N(X_{t+1}; \tilde{\mu}_t, \tilde{\beta}_t I)$$

$$\tilde{\mu}_t(X_t, X_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t+1})}{1 - \bar{\alpha}_t} X_t + \frac{\sqrt{\alpha_{t+1}} \beta_t}{1 - \bar{\alpha}_t} X_0$$

! 无法推理

$$\Downarrow \text{任意步加噪反解 } X_0 = \frac{X_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}}$$

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(X_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \right) \epsilon$$

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t+1}}{1 - \bar{\alpha}_t} \beta_t$$

没有未知数!

• X_t : 输入给网络的当前图像 (已知)

• $\alpha_t, \bar{\alpha}_t, \beta_t$: 人为设定超参 (已知)

• ϵ : 导致 X_0 变成 X_t 的那个噪声 (未知)

不需要预测 x_{t+1} , 也不需要预测原图 x_0 .
 \Rightarrow 训练网络 $\epsilon_\theta(x_t, t) \rightarrow$ 预测噪声
 $\epsilon_\theta \rightarrow \tilde{\mu}_t \xrightarrow{\text{采样}} x_{t+1} \rightarrow \dots x_k \rightarrow x_0$
 $\searrow \tilde{\mu}_t(x_0, x_t) + \sqrt{\beta_t} \epsilon \sim \mathcal{N}(0, 1)$
 该噪声对于第 t 个逆向步来说是分别预测出来的 (每一步独立预测), 但含义时从 0 到 t 的噪声.

2. 关于方差 β_t

- 神经网络在设定方差时直接固定.
- 物理含义: σ : 这一步去噪有多大随机性/模糊度.
 μ : 图像长什么样.
- DDPM (OpenAI) 发现: 预测小学习方差, 生成的图片效果不明显, 但 \log -likelihood (对数似然) 会显著提升, 且允许用更少的步数生成图片.

三. 常见问题

1. 一下取到多大的时候, x_T 满足 $\mathcal{N}(0, 1)$? Ans. 取大些.

2. Why $\beta_t = 1 - \alpha_t$? i.e. $\mu^2 + \sigma^2 = 1$

Ans. 保证均值 $\rightarrow 0$ 时, 方差 $\rightarrow 1$.

3. 能否跳步?

Ans. $P(x_{t+1} | x_t, x_0)$ 是基于马尔可夫性质建立的. 所以要在逆向过程跳步的话, 需要去马尔可夫化 \rightarrow DDIM.
 (本质是一种采样方式).

4. 为什么不用 UNet 去做 $x_T \xrightarrow{\text{预测}} x_{T-1}$?

Ans. 直接去预测 x_{T-1} 类似退化为风格任务. 此时每一个 x_T 都对应一个 x_0 , 即每一步都 deterministic. 取 2 个一样的 x_T 会得到 2 个一样的 x_0 .

但去做 $P(x_{t+1} | x_t)$ 多样性更高. $x_T \Rightarrow x_0$
 $\Rightarrow x_0'$
 (因为涉及采样)

四. Loss Function.

$$L(\theta) = E_{t, x_0, \epsilon} [\| \epsilon - \epsilon_\theta(\sqrt{a_t}x_0 + \sqrt{1-a_t}\epsilon, t) \|^2]$$

$$Loss = \| \epsilon - \epsilon_\theta(x_t, t) \|^2$$

- 上述是简化后的 Loss: 将所有 t 的权重都设为 1, 但简化后生成的图片质量反而更好。
- 由变分下界推导, 我们要优化的是两个高斯分布 (后验 q 和模 p) 之间的 KL 散度。

$$L_{vlb} = E \left[\sum_{t=1}^T \frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\alpha_t)} \| \epsilon - \epsilon_\theta(x_t, t) \|^2 \right]$$

• Why 简化更好?

Ans. • 加权 Loss 会更多关注 t 很小的步骤 (纠结于 ^{不可感知} imperceptible 的细节), 通常是图像几乎完全无噪的微小噪声。

• 不加权: 相当于增加了 t 较大时的权重, 迫使模型更好地学习图像的整体结构和内容。

五. DDPM 中的 UNet 结构.

1. DDPM 中特有改动.

• 同一个 U-Net 要处理 $t=1 \sim 1000$ 所有情况 \rightarrow 需知道现在第几步。

• 方法: 正弦位置编码 (Sinusoidal Positional Embeddings).

◦ 输入: 标量 t

◦ 编码: 正/余弦 \rightarrow 高维向量

◦ 注入: 送入 U-Net 的每个残差块中:

$$\text{Scale \& shift: } \text{Feature}_{\text{new}} = \text{Feature}_{\text{old}} \times (1 + \text{Scale}_t) + \text{Shift}_t$$