

Stable Diffusion.


1. 使用了 CLIP (Contrastive Language-Image Pre-training) 中的 Text Encoder

2. Variational AutoEncoder.

(1) 用于压缩前/逆向过程的维度以提高计算效率
→ latent diffusion.

→ 将学习 data distribution \rightarrow latent representation of the data.


(2) 不压缩, 同时也学习了 latent space.



z represents the parameters of a multivariate distribution (多元分布)
(Gaussian) 学的是 μ 和 σ .

3. Architecture.

(1) Text 2 Image



(2) Image 2 Image

将 Random Noise 换成真实图片; encoder 得到的是 Add noise to latent.

- 添加的噪声少, 生成的自由度广
- 少的噪声 means 不能从根本上改变图片.
- 噪声多少 \Rightarrow 对原图有多大注意力

(3) In-Painting. (fool the model) \rightarrow 引入约束

① 推理时干预 (Inference-time Strategy)

· 代表作: RePaint

· 思想: 不重新训练模型, 在去噪过程作弊.

$$X_{t-1}^{\text{final}} = \underbrace{\text{Mask} \cdot X_{t-1}^{\text{pred}}}_{\substack{\text{被遮住的部分} \\ \text{使用模型推断结果}}} + (1 - \text{Mask}) \cdot X_{t-1}^{\text{known}}$$

↑
被遮住的部分
使用模型推断结果

↑
保留区域: 不是直接将原图 X_0 贴上
而是前向到 $t-1$ 强度的噪声.

· 问题: 边缘不连贯.

计算量大

\rightarrow 生成 X_{t-1} 后, 强行加噪回 X_t , 反复横跳.

② 模型微调 (Fine-tuning Strategy)

· 代表作: Stable Diffusion Inpainting Model.

· 思想: 将输入通道 4 \rightarrow 9 \Rightarrow UNet.

1° 当前噪声图 (4通道): Z_t

2° 豪版图 (13通道): Mask

3° 被豪版遮挡的原图 (4通道): Masked Image Latent.

③ ControlNet Inpainting

训练 ControlNet 模块.

4. VAE (Variational Autoencoder)

(1) · 原理: Not learning how to compress the data but learning a latent space which are the parameters of a multivariate Gaussian distribution.

\rightarrow Actually, the VAE is trained to learning the μ and σ .

\rightarrow Then we will sample the distribution.

log6.

5. 核心参数

① strength: 重绘程度

- 决定了生成图和原图有多像 图片还未完全变成噪声.
- 代码逻辑: 起始噪声水平 (从中间步开始降噪)

② do-cfg = True: 启用分类器引导.

- 是否叫懂人话

- 代码逻辑: 如果为 True, 模步的每步预测会同时计算 2 个结果:
 - 1° 有提示词预测 (output-cond): 完全猜, 根据双向 prompt 或室内名去预测.
 - 2° 无 ~ (output-uncond): 完全猜, 根据双向 prompt 或室内名去预测.

3° 将 2 种 output 结合

- 如果不开启, 生成虽然自然, 但不会理会 prompt.

③ cfg-scale: 引导系数

- 代码逻辑: 最终结果 = 无引导结果 + 系数 (有引导 - 无引导)
- < 2: 不理会 prompt
- > 15: 强行匹配每一个词.

6. 代码小思考

(1) 调度策略: 原 DDPM 用的 Linear Schedule, SD 中用的无开方做插值再平方回去的 Scaled Linear Schedule, why?

Ans. DDPM 是在像素空间训练的, SD 是在 Latent space 上训练的, 对于方差和分布更敏感. 采用 SLS, 让 β 在初期增长得慢一些, 适合 Latent Space 的信噪比变化规律.

(2) 项目中采用的是 Pespaced DDPM, 而非 DDIM?

Ans. 因为每步噪声采样的 variance $\neq 0$, 如果为 0 的话才是 DDIM.

(3) VAE 中添加的噪声和 diffusion 前后加的噪声的区别?

Ans. VAE 把图片压缩后, 得到的是一个概率分布 (μ, σ) ,

需要从中取出一个具体的 Latent 向量 z 为后面的流程用，
因此需要重参数化采样： $\text{Latent} = \text{Mean} + \text{Variance} \times \frac{\text{Noise}}{\sigma}$ 。
没有这个噪音，VAE 无法训练退化为普通的编码器。

$$(\mathbb{E}[z | x_1, x_2, \dots, x_n]) \sim \mathcal{N}(\text{Mean}, \text{Variance}) \quad \frac{(\mathbb{E}[z | x_1, x_2, \dots, x_n])^2}{(\mathbb{E}[z | x])^2} = (\mathbb{E}[z | x])^2$$

$$3 \cdot \mathbb{E}[z | x_1, x_2, \dots, x_n] + \text{Noise} \cdot \sqrt{3 \cdot \text{Variance}} = 3z + (\text{Noise} \cdot \sqrt{3}) = z$$


$$3 \cdot \overline{z} + \text{Noise} \cdot \sqrt{3 \cdot \text{Variance}}$$

$$(\text{Noise} \cdot \sqrt{3}) \times \text{Variance} \leq$$

$$(\mathbb{E}[z | x_1, x_2, \dots, x_n])^2 \leq \text{Variance} + (\mathbb{E}[z | x])^2 = \text{Variance}$$

$$(\mathbb{E}[z | x_1, x_2, \dots, x_n]) \frac{\sqrt{3 \cdot \text{Variance}}}{\sqrt{\text{Variance}}} + \text{Noise} \cdot \sqrt{\text{Variance}} =$$

跟前一个步骤一样



代码知识:

1. SiLu



$$SiLu(x) = x \cdot G(x) = \frac{x}{1+e^{-x}}$$

优势: ① 0点可导

② 负值区梯度有传递,

防止神经元死亡.

③ 隐式正则化

2. Normalization

$$y = \frac{x - E[x]}{\sqrt{Var[x] + \epsilon}} * \gamma + \beta$$

(不改变形状)

标准化 \rightarrow 射影变换 (γ, β 可学习参数)

[图]

	归一化范围	依赖 batch-size	应用场景	比喻
Batch Norm	同一通道, 所有照片	✓ (劣势)	CNN	全校单杆测温
Layer Norm	同一图片, 所有通道	✗	NLP	个人综合总分
Instance Norm	同一图片, 单一通道	✗	风格迁移 GAN	个人单科
Group Norm	同一图片, 一组通道	✗	VAE, Stable Diffusion	个人理/文科

3. 卷积输出公式

$$H_{out} = \left\lceil \frac{H_{in} + P - K}{S} \right\rceil + 1$$

• 1x1 卷积:

物理含义: 作用在 Channel 维度上的全连接层。
把每个像素点的特征向量做一次矩阵乘法, 让特征间相互融合.

作用: ① 通道间信息交流

② 升维与降维

③ 增加非线性 (后面加激励函数).

4. • nn.Sequential: 只能一种输入 x , 然后把输出传给下一层.

• SwitchSequential: 处理 UNet 每层不同的需求

↓ 包装

• ModuleList : 文件夹

▷ Why UNet 用 ModuleList 包裹许多 SwitchSequential?

Ans. UNet 的编码器 (Downsampler) 每经过一层都需保存当前特征图, 以便后面解码器 (Upsampler) 的 concat .

卷积层: 图像 x

残差层: 图像 $x + \text{时间} t$

注意力层: 图像 $x + \text{文本 context}$.